Slovenski NLTK označevalnik

Niko Colnerič Nejc Banič

Fakulteta za Računalništvo in Informtiko Univerza v Ljubljani

January 16, 2012

Motivacija

This is a short introduction to Beamer class.

Implementirani označevalniki

- Trigram tagger
- Brill tagger
- classifier based Naive Bayes tagger

JOS korpus

NLTK trainer

Postopek treniranja označevalnikov

- Transformacija .XML korpusa v .pos
- Treniranje z skripto iz NLTK-trainer
- Ocenjevanje točnosti
- Ocenjevanje hitrosti

Lep je dan, vse diši že po pomladi

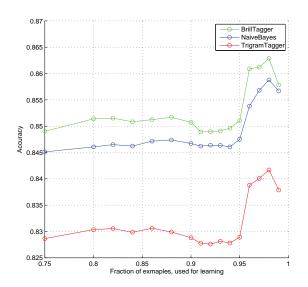
```
( Lep — PPNMEIN ) - pridevnik
( je — GP-STE-N ) - glagol
( dan — SOMEI ) - samostalnik
( , — , ) - ni razlage
( vse — ZC-SEI ) - zaimek
( diši — GGNSTE ) - glagol
( že — L ) - členek
( po — DM ) - predlog
( pomladi — SOZEM ) - samostalnik
( ! — ! ) - ni razlage
```

Celoten MSD za *Lep*

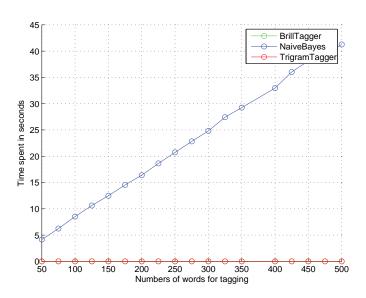
		٠	
prid	levn	I	k

splošni	
moški	
ednina	
imenovalnik	
0	
0	
0	
0	
0	
nedoločeno	
ne	
0	
0	
0	
0	

Rezultati natančnost



Rezultati hitrost



Zaključek in izboljšave