Slovenski NLTK označevalnik

Niko Colnerič Nejc Banič

Fakulteta za Računalništvo in Informtiko
Univerza v Ljubljani

January 16, 2012

Motivacija

- NLTK - Natural Language Toolkit (Python 2.7)
- Označevalnik (tagger) besedam pripiše oblikoslovne oznake
- Težave z dvoumnostjo
- Uporabnost za nadaljno procesiranje teksta
- Tega so nas učili v šoli ☺

Implementirani označevalniki

- **Trigram označevalnik**
  a priori najbolj verjetno oznako v kontekstu dolžine 3

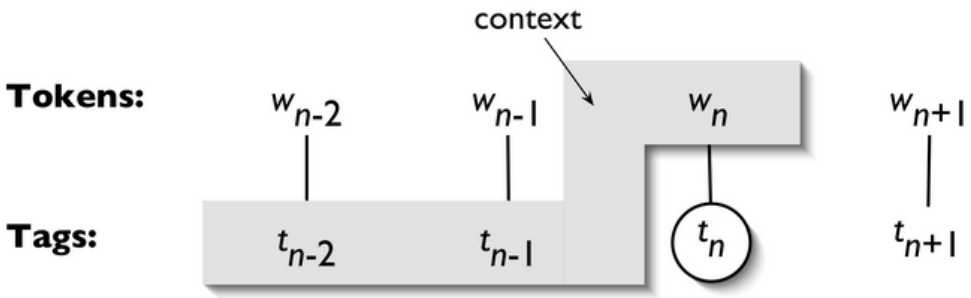

- **Brillov označevalnik**
  ugane oznako vsako besede, nato popravi svoje napake tako, da uporabi seznam transformacijskih pravil
- označevalnik na podlagi **naivnega Bayes-ovega klasifikatorja**
  predpostavi pogojno neodvisnost atributov pri danem razredu

JOS korpus

- korpus = velika in strukturirana zbirka besedil
- Jezikoslovno Označevanje Slovenskega jezika (IJS)
- Zbirko besedil s ročno preverjenimi jezikoslovnimi oznakami
- *.XML* datoteka
- Uporabila sva *jos1M* - 1 milijon označenih besed
- MULTEXT-East V4 specifikacija
- MSD (morphosyntactic descriptions) - definirajo kategorije oz. besedne vrste
- Namenjena spodbujanju razvoja jezikovnih tehnologij za slovenski jezik

NLTK trainer

- Uporabljen za treniranje NLTK objektov - označevanlikov
- *Train NLTK objects with zero code*
- Dobro dokumentiran
- Prosto dostopen na Github-u

Postopek treniranja označevalnikov

1. Transformacija *.XML* korpusa v *.pos*
2. Treniranje z skripto iz NLTK-trainer
3. Ocenjevanje točnosti
4. Ocenjevanje hitrosti

Primer

Lep je dan, vse diši že po pomladi!

(Lep — PPNMEIN) - pridevnik
(je — GP-STE-N) - glagol
(dan — SOMEI) - samostalnik
(, — ,) - ni razlage
(vse — ZC-SEI) - zaimek
(diši — GGNSTE) - glagol
(že — L) - členek
(po — DM) - predlog
(pomladi — SOZEM) - samostalnik
(! — !) - ni razlage

Celoten MSD za *Lep*

pridevnik	
vrsta	splošni
spol	moški
število	ednina
sklon	imenovalnik
živost	0
vid	0
oblika	0
oseba	0
nikalnost	0
stopnja	nedoločeno
določnost	ne
število_svojine	0
spol_svojine	0
naslonskost	0
zapis	0

Rezultati natančnost

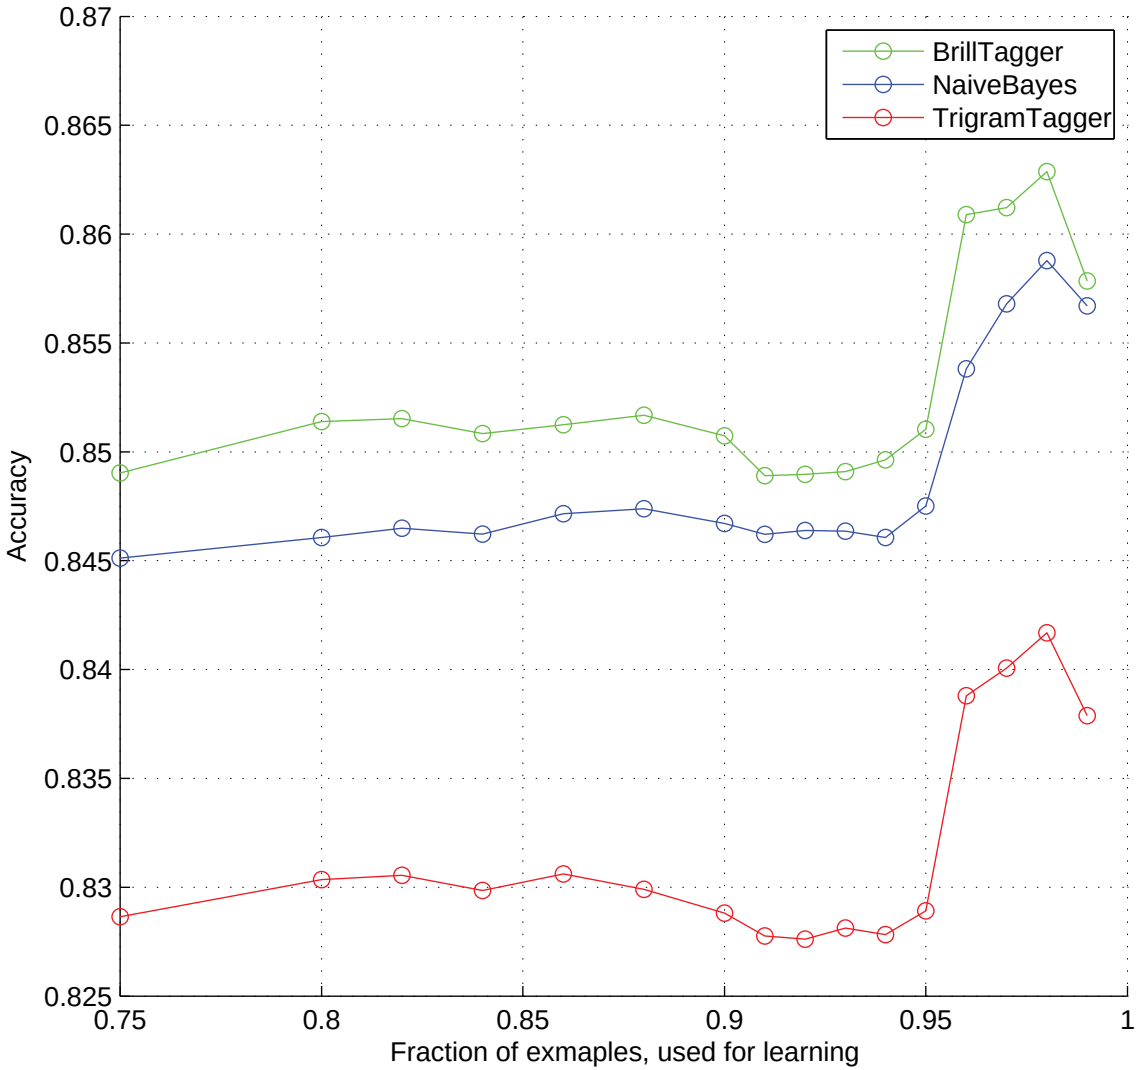

Rezultati hitrost

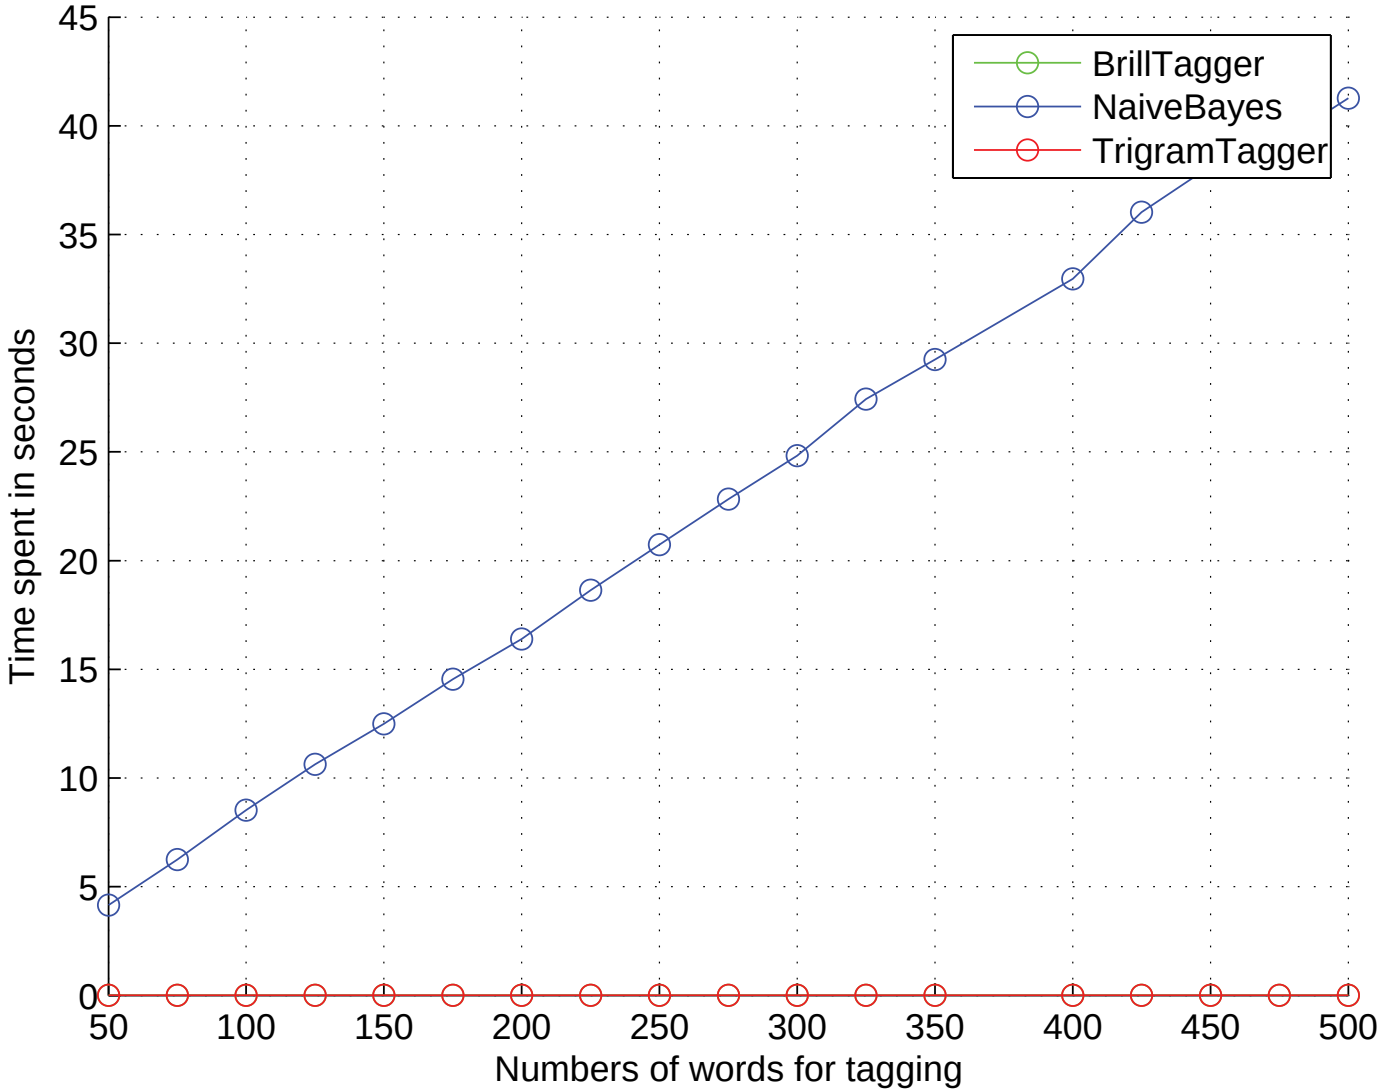

Zaključek, izboljšave

- Brill in Trigram sta hitra, NaiveBayes veliko počasnejši
- Najbolj natančen Brill, najmanj Trigram
- $\Rightarrow$ Priporočama uporabo Brill označevalnika
- Vključitev v NLTK
- Dostopno na:
  `https://github.com/nikicc/slovene-nltk-tagger`

- Z lahkoto bi zgradili tudi druge označevalnike, ki bi lahko bili boljši ali hitrejši
- Vključitev drugih korpusov, bi bila koristna